

卒業論文 深層学習による生成モデリング

小林景研究室
海老澤優

February 1, 2022

目次

- ① はじめに
- ② 生成モデルとは
- ③ AE (Autoencoder)
- ④ VAE (Variational Autoencoder)
- ⑤ GAN (Generative Adversarial Networks)
- ⑥ 顔画像の生成

目次

- ① はじめに
- ② 生成モデルとは
- ③ AE (Autoencoder)
- ④ VAE (Variational Autoencoder)
- ⑤ GAN (Generative Adversarial Networks)
- ⑥ 顔画像の生成

はじめに

- GAN (Generative Adversarial Networks) は 2014 年にイアン・グッドフェローらによって提案された生成モデルで、画像生成のモデルとしてよく知られている。本物のような画像を多様に生成できる




Figure: celebA の本物画像 (左) と DCGAN で生成した画像 (右)

はじめに

- GAN は本物のような画像を多様に生成できる手法であるが、それが達成されているかを評価することが難しいという課題がある。
→次元削減の手法を用いて生成画像の特徴を可視化することはできないか？
- UMAP を用いて GAN の精度の可視化を試みた。
※ UMAP は多様体学習の手法のひとつで、データの非線形次元削減を行う。

目次

- ① はじめに
- ② 生成モデルとは
- ③ AE (Autoencoder)
- ④ VAE (Variational Autoencoder)
- ⑤ GAN (Generative Adversarial Networks)
- ⑥ 顔画像の生成

生成モデルとは

- 生成モデルとは、データの生成過程を確率分布でモデル化し、新しいデータを生成できるモデルである。




Figure: 識別モデルと生成モデル

目次

- ① はじめに
- ② 生成モデルとは
- ③ AE (Autoencoder)
- ④ VAE (Variational Autoencoder)
- ⑤ GAN (Generative Adversarial Networks)
- ⑥ 顔画像の生成

AE (オートエンコーダ)

- AE は深層ニューラルネットワークにより画像の圧縮と復元を通して入力した画像と似た画像を復元するモデル.
- 画像を潜在変数に圧縮するエンコーダと潜在変数から画像に復元するデコーダを学習する.
- AE は画像を復元しているが, 生成モデルではない.
→ニューラルネットが複雑すぎて連続性が消失.




Figure: AE の全体像

- 損失関数は以下の再構成誤差で定義される (画素値は 0~1) .

$$J^{REC} = - \sum_{i=1}^d (x_i \log y_i + (1 - x_i) \log(1 - y_i))$$

目次

- ① はじめに
- ② 生成モデルとは
- ③ AE (Autoencoder)
- ④ VAE (Variational Autoencoder)
- ⑤ GAN (Generative Adversarial Networks)
- ⑥ 顔画像の生成

VAE (変分オートエンコーダ)

- VAE は、潜在変数を標準正規分布に従う確率変数でモデル化する。
- 学習後はエンコーダは不要となり、標準正規分布に従う確率変数をデコーダに入力すれば、画像を確率的に生成できるようになる。よって、VAE は生成モデルと言える。
- 画像を一点ではなく分布にエンコードすることで画像間の近さと潜在空間の近さが保存される。




Figure: VAE の全体像

VAE (変分オートエンコーダ)

損失関数は再構成誤差 J^{REC} と標準正規分布との近さを表す正則化誤差 J^{REG} の和で定義される.

$$J = J^{REC} + J^{REG}$$

$$J^{REC} = - \sum_{i=1}^d (x_i \log y_i + (1 - x_i) \log(1 - y_i))$$

$$J^{REG} = -\frac{1}{2} \sum_{j=1}^{\tilde{d}} (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2)$$

ただし, μ_j と σ_j はそれぞれ平均ベクトル, 分散ベクトルの第 j 成分. J^{REG} は $\mu_j = 0, \sigma_j = 1$ ($1 \leq j \leq \tilde{d}$) で最小値をとる.

VAE の実装

- MNIST データを学習させた。潜在変数の次元数は 10 とした。



Figure: 本物画像 (1 行目), VAE で復元した画像 (2 行目), 潜在空間上で 7 から 2 に連続的に変化した画像 (3 行目)



Figure: 標準正規分布の乱数から VAE で得られた生成画像

- VAE は標準正規分布で明示的にモデル化しており、ピクセル単位で最適化するため実際の画像に存在する複雑性を表現できず、生成画像が本物画像よりも全体的にぼやけるという問題点がある。

VAE AE と VAE の潜在変数の比較

- 潜在空間の次元数を 2 として学習をやり直し、AE と VAE の潜在空間をプロットした。
- 正則化誤差により、潜在変数がまとまりデータ空間の近さが潜在空間でも保存される。




Figure: AE の潜在空間




Figure: VAE の潜在空間

目次

- ① はじめに
- ② 生成モデルとは
- ③ AE (Autoencoder)
- ④ VAE (Variational Autoencoder)
- ⑤ GAN (Generative Adversarial Networks)
- ⑥ 顔画像の生成

GAN (敵対的生成ネットワーク)

- GAN は Generative Adversarial Networks の略で、日本語では敵対的生成ネットワークと呼ばれる。
- 画像を生成するネットワークである生成器と本物画像と生成画像を判別するネットワークである識別器が競い合うように学習が進む。
- 潜在変数の確率分布に明示的な仮定をせず、ニューラルネットワークを用いて確率分布を最適化することでより複雑な確率分布を扱えるようになる。結果、GAN は VAE に比べて鮮明な画像を生成できるようになる。





Figure: GAN の全体像

GAN 例えるならこんな感じ



GAN 識別器の学習

- 識別器は入力画像が本物 (1) か偽物 (0) かを判別する。
- 画像が本物である確率を出力し、正解との差をもとに損失を求める。




Figure: 識別器の学習

GAN 生成器の学習

- 生成器は乱数ベクトルから画像を生成する。
- 生成画像を識別機に通し、識別信号と正解ラベル 1 との損失を求める。つまり、生成器は識別器を騙すように学習を進める。




Figure: 生成器の学習

GAN 全体の学習

GAN の学習では、識別器と生成器のパラメータを交互に最適化する。学習の1回のイテレーションで次の2つのステップを実行する。

- ① 生成器のパラメータを固定して、識別器のパラメータを最適化
- ② 識別器のパラメータを固定して、生成器のパラメータを最適化

GAN の損失関数は以下の式になる。

$$\min_G \max_D L(D, G) = E_{p_d}[\log D(x)] + E_{p_z}[\log(1 - D(G(z)))]$$

x : 本物画像, z : ノイズベクトル, $D(\cdot)$: 識別器の出力, $G(\cdot)$: 生成器の出力
 $p_d(\cdot)$: データ分布の密度, $p_z(\cdot)$: ノイズ分布の密度

GAN の問題点

- 学習が停滞しやすい (勾配消失問題)。
- 生成器を騙しやすい画像のみを生成して多様性を失う (モード崩壊)。

GAN の実装

VAE のときと同様，MNSIT データを GAN で実装した．GAN のモデルとして，生成器と識別器に畳み込みニューラルネットワークを用いた DCGAN というモデルを用いた．



Figure: DCGAN で生成した画像

※参考



Figure: VAE で生成した画像


まとめると...

生成モデルになるよう改良

より鮮明に


AE(オートエンコーダ)

- ・そもそも画像の次元削減&復元のモデル.
- ・エンコーダとデコーダのネットワークが複雑すぎて、データ空間の近さと潜在変数の近さが対応せず、生成モデルとして機能しない.




VAE(変分オートエンコーダ)

- ・画像を一点ではなく分布にエンコード（同じ画像が毎回少しずつれてプロットされる）ので、データ空間の近さと潜在空間の近さが対応.
- ・確率分布を明示的に仮定しているので、複雑性が失われ生成画像がぼやける.



GAN(敵対的生成ネットワーク)

- ・確率分布を暗黙的に仮定しニューラルネットで最適化したことで鮮明な画像を生成できる.
- ・学習が安定しなかったり、識別器を騙しやすい画像のみを生成してしまい多様性が失われるなど課題も多い.



目次

- ① はじめに
- ② 生成モデルとは
- ③ AE (Autoencoder)
- ④ VAE (Variational Autoencoder)
- ⑤ GAN (Generative Adversarial Networks)
- ⑥ 顔画像の生成

顔画像の生成

celebA データセットという有名人の顔画像を集めたデータセットを DCGAN で学習し、顔画像の生成を行った。イテレーション数を 50000, バッチサイズを 100 として学習を行った。







Figure: celebA の本物画像（左）と DCGAN で生成した画像（右）

顔画像の生成 学習の過程


イテレーション 10000 ごとに生成された画像を表示する。



顔画像の生成 学習の過程




顔画像の生成 学習の過程



顔画像の生成 生成画像の分布

- 生成画像が本物画像の分布の中にどのように広がっているかを可視化するため、本物画像 1000 枚を UMAP を用いて 2 次元に次元削減し、そこに生成画像 64 枚を射影した。
※ UMAP は非線形次元削減のひとつ。局所的な距離構造と大域的な距離構造を保存する。
- 生成画像が 1 次元的に分布している。
→ 生成器が識別器を騙しやすい特徴を学習した可能性。
- 生成画像は本物画像の散布図の境界付近に射影されたものが多い。



顔画像の生成 生成画像の分布

境界付近に射影された生成画像はくずれた画像が多い。
⇒ 生成画像の評価を可視化できる。



Figure: 本物画像の散布図の境界付近に射影された生成画像




Figure: 本物画像の散布図の内側に射影された生成画像

顔画像の生成 生成画像の分布

散布図を局所的に見ると、生成画像は近くの特徴を併せ持っているように見える。

(大きめにプロットされているのが生成画像)

⇒ 崩れた画像は距離が近い本物画像が少ないため、境界に射影される。



今後の課題

- UMAP の問題点
距離をユークリッド距離で計算しているため、背景色の影響を大きく受けていることが考えられる。
⇒ 画像に特化した距離を用いた次元削減法を使う必要がある。
※画像間距離の指標としては、PSNR, SSIM, FSIM などがある。
- GAN がうまくいく理由があまり分かっていないので理解したい。

参考文献

- 毛利拓也, 大郷友海, 嶋田宏樹, 大政孝充, むぎたろう, 寅蔵, もちまる. GAN ディープラーニングハンドブック. 秀和システム
- Diederik P Kingma, Max Welling. (2013) . Auto-Encoding Variational Bayes.
- Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, Yoshua Bengio. (2014) . Generative adversarial nets. Advances in neural information processing systems, 27, 2672-2680.