


統計科学特論B
幾何学的な統計手法とその理論
第10回 (2021.06.14)

確率分布間の距離と
ダイバージェンス

担当： 数理科学科 小林 景



確率分布の空間の統計学

前回まで：1 点がデータ点（のとり得る値）である空間
（データ空間）

今回から：1 点が確率分布（のとり得る値）である空間
（モデル空間）

第 1 0 回 確率分布間の距離とダイバージェンス

第 1 1 回 Wasserstein距離

第 1 2 回 情報幾何学入門

第 1 3 回 質問の日

確率変数間の距離と確率分布間の距離

- 今回は特に断らない限り，確率変数は実スカラー値とする
 - 確率変数間の距離 $\neq$ 確率分布間の距離
(復習) 確率変数の収束 (確率収束, 概収束)
 $\neq$ 確率分布の収束 (分布収束)
 - 確率変数間の距離の例：
 - ✓ L^p 距離： $E[|X - Y|^p]^{1/p}$
 - ✓ probability metric： $\inf\{\epsilon > 0 \mid P(d(X, Y) > \epsilon) < \epsilon\}$
 - ※ 特に $d(X, Y) = |X - Y|$ のときはKy Fan距離
 - ※ 確率収束を定める距離
- ➡ 以後は確率分布間の距離のみを扱う

確率分布間の距離

- 全変動距離
- Hellinger 距離
- Kolmogorov-Smirnov 距離
- Prokhorov 距離
- χ^2 距離
- RKHSを用いた分布間距離

順に紹介していく

全変動距離(total variation distance)

$$d_{TV}(p_1, p_2) := \frac{1}{2} \int |p_1(x) - p_2(x)| dx$$

- $\sup_{A \subset X} (P_1(A) - P_2(A))$ と定義することもできる
- つまり, 同じ事象に対する確率の差の最大値である
- 上記の 2 倍の $d_{TV}(p_1, p_2) = \frac{1}{2} \int |p_1(x) - p_2(x)| dx$ を定義とすることもある
- その場合は L^p 距離 $d_p(p_1, p_2) = \left(\int |p_1(x) - p_2(x)|^p dx \right)^{1/p}$ の $p = 1$ の場合である

Hellinger距離, Hellinger-Kakutani距離

$$d(p_1, p_2) := \left(2 \int (p_1(x)^{1/2} - p_2(x)^{1/2})^2 dx \right)^{1/2}$$

- $d(p_1, p_2) = 2 \left\{ 1 - \int (p_1(x)p_2(x))^{1/2} dx \right\}^{1/2}$ も同値
- $\rho(p_1, p_2) := \int (p_1(x)p_2(x))^{1/2} dx$ はFidelity similarityとよばれる.
- $\arccos(\rho(p_1, p_2))$ はBhattacharya角度, もしくはFisher距離 (の2倍) とよばれる.
- $-\ln \rho(p_1, p_2)$ はBhattacharya距離とよばれる.

χ^2 距離, χ^2 ダイバージェンス

- Pearson's χ^2 distance: $\chi^2(f_1, f_2) := \sum_x \frac{(f_1(x) - f_2(x))^2}{f_2(x)} = \left(\sum_x \frac{f_1(x)^2}{f_2(x)} \right) - 1$
- Neyman's χ^2 distance: $\chi^2(f_1, f_2) := \sum_x \frac{(f_1(x) - f_2(x))^2}{f_1(x)} = \left(\sum_x \frac{f_2(x)^2}{f_1(x)} \right) - 1$
- 対称性がないので, 正確には擬距離
- 対称化した $\sum_x \frac{(f_1(x) - f_2(x))^2}{f_1(x) + f_2(x)}$ を χ^2 距離とよぶこともある
- 多項分布 $(x_1, \dots, x_k) \sim \text{Multi}(n, p_1, \dots, p_k)$ の仮説が正しいかの検定には, $m_i := np_i$ ($i = 1, \dots, k$) 以下のカイ二乗統計量を用いる

$$\chi_n^2 := \sum_{i=1}^k \frac{(x_i - m_i)^2}{m_i} = n \sum_{i=1}^k \frac{\left(\frac{x_i}{n} - p_i \right)^2}{p_i}.$$

- これは, 経験分布 (頻度分布) とモデル分布とのピアソン χ^2 距離であり,
$$\chi_n^2 \xrightarrow{d} \chi^2(k-1) \quad (n \rightarrow \infty)$$

Kolmogorov-Smirnov距離

$$\begin{aligned} d(P_1, P_2) &:= \sup_{x \in \mathbb{R}} |P_1(X \leq x) - P_2(X \leq x)| \\ &= \sup_{x \in \mathbb{R}} |F_1(x) - F_2(x)| \end{aligned}$$

- 経験分布関数 $F^{(n)}(x) = \frac{1}{n} \sum_{i=1}^n 1(x_i \leq x)$ と分布関数 $F(x)$ とのKolmogorov-Smirnov距離は、Kolmogorov-Smirnov統計量と呼ばれ、データが分布関数 $F(x)$ からのi.i.d.標本であるかどうかを検定するための統計量として用いられる.
 - $d_{KS}(F^{(n)}, F) \xrightarrow{a.s.} 0$ (Glivenko-Cantelli theorem)
 - $\sqrt{n} d_{KS}(F^{(n)}, F) \xrightarrow{d} \sup_x B(F(x))$
(A corollary of Donsker's theorem)
- ただし, $B(\cdot)$ はBrownian bridge.

Prokhorov 距離, Prokhorov-Levi距離

$$d(P_1, P_2) := \inf \{ \epsilon > 0 \mid P_1(X \in A) \leq P_2(X \in A^\epsilon) + \epsilon \text{ かつ} \\ P_2(X \in A) \leq P_1(X \in A^\epsilon) + \epsilon \text{ for } \forall A \in \mathfrak{B}(M) \}$$

ここで, X は距離空間 (M, d) 上のボレル集合族 $\mathfrak{B}(M)$ で可測な確率変数, $A^\epsilon := \{x \in M \mid d(A, x) < \epsilon\}$

- $\mathbb{R}$ 上に限った場合は, Levi 距離とよばれる.
- この距離での収束は, 分布収束 (確率測度の弱収束) と同値である.
- 距離空間 (M, d) がポーランド空間 (完備可分距離付け可能空間) ならば, M 上の全確率測度にProkhorov距離を導入した空間もポーランド空間となる.

再生核ヒルベルト空間 (RKHS) を用いた 分布間距離 1

- 集合 $\mathcal{X}$ とその上の正定値カーネル関数 $k(\cdot, \cdot)$ を定めるとRKHS $\mathcal{H}_k$ が定まり, 各点 $x \in \mathcal{X}$ に対応する $k(\cdot, x) \in \mathcal{H}_k$ を構成できるのであった.

- $\mathcal{X}$ 上の確率分布 P および標本 $x_1, \dots, x_n$ が与えられたとき,

$$m_P^k := \int k(\cdot, x) dP_x, \quad \hat{m}_n^k := \frac{1}{n} \sum_{i=1}^n k(\cdot, x_i)$$

と定める. k が特性的(characteristic)とよばれる性質をみたすカーネル関数であるとき, $P \mapsto m_P^k \in \mathcal{H}_k$ は単射となる.

- 以上を用いて $\mathcal{X}$ 上の確率分布 P, Q 間に以下の距離を定義できる.

$$M_k(P, Q) := \|m_P^k - m_Q^k\|_{\mathcal{H}_k}$$

- カーネル関数を変えることで様々な分布間距離を定義できる.

再生核ヒルベルト空間 (RKHS) を用いた 分布間距離 2

- 2 標本 $x_1, \dots, x_n$ および $y_1, \dots, y_\ell$ が与えられたときは,

$$\hat{m}_{x,n}^k := \frac{1}{n} \sum_{i=1}^n k(\cdot, x_i) \text{ および } \hat{m}_{y,\ell}^k := \frac{1}{\ell} \sum_{i=1}^{\ell} k(\cdot, y_i) \text{ を用いて,}$$
$$\|\hat{m}_{x,n}^k - \hat{m}_{y,\ell}^k\|_{\mathcal{H}_k}^2 = \frac{1}{n^2} \sum_{i,j=1}^n k(x_i, x_j) + \frac{1}{\ell^2} \sum_{i,j=1}^{\ell} k(y_i, y_j)$$
$$- \frac{2}{n\ell} \sum_{i=1}^n \sum_{j=1}^{\ell} k(x_i, y_j)$$

と直接計算できる形になる.

- ガウシアンカーネルを用いた場合は, 上記の距離の最小化は, $x_1, \dots, x_n$ のガウシアン平滑化分布の, $y_1, \dots, y_\ell$ における尤度の和を最大化していることに対応する.

- 詳細はVenturini(2015) や福水(2010) 参照

確率分布間のダイバージェンス

- ダイバージェンス $D(P_1||P_2)$

= 分布間の近さの規準だが，距離の公理は満たしていないもの

(1) $D(P_1||P_2) \geq 0$ for $\forall P_1, P_2$ (非負性)

(2) $P_1 = P_2 \Leftrightarrow D(P_1||P_2) = 0$ (識別性)

の2条件のみを要請することが多い。

以下のような例がある

- Kullback-Leibler divergence
- Bregman divergence
- Csizarの f -divergence
- α ダイバージェンス
- Renyi距離

Kullback-Leibler Divergence (KL divergence)

$$KL(f_1 \parallel f_2) := \int f_1(x) \log \frac{f_1(x)}{f_2(x)} dx$$

- 統計学や情報理論で最もよく使われるダイバージェンスの1つ
- 非負性, 識別性は成立
- 対称性, 三角不等式は不成立

$$\bullet D(f_1, f_2) := \int f_1(x) \log \frac{f_1(x)}{f_2(x)} dx + \int f_2(x) \log \frac{f_2(x)}{f_1(x)} dx$$

$$\bullet D'(f_1, f_2) := \int f_1(x) \log \frac{f_1(x)}{(f_1(x)+f_2(x))/2} dx + \int f_2(x) \log \frac{f_2(x)}{(f_1(x)+f_2(x))/2} dx$$

のような対称化されたダイバージェンスを用いることもある.
後者はJensen-Shannonダイバージェンスとよばれる (次頁)

- 分布 P_2 の台が分布 P_1 を含んでいないときは発散する.

Jensen-Shannon divergence

$$JS(f_1, f_2) := \int f_1(x) \log \frac{f_1(x)}{(f_1(x) + f_2(x))/2} dx + \int f_2(x) \log \frac{f_2(x)}{(f_1(x) + f_2(x))/2} dx$$

- ✓ 通常の対称化KLダイバージェンスと違い，常に有限値をとる
- ✓ 機械学習のGANに用いられる
- ✓ 一般化した以下の量は確率分布の集合ばらつきの指標として用いられる

$$D(f_1, \dots, f_m) := \sum_{i=1}^m \int f_i(x) \log \frac{f_i(x)}{m^{-1} \sum_{j=1}^m f_j(x)} dx$$

cf: 対称化KLダイバージェンス

$$D(f_1, f_2) := \int f_1(x) \log \frac{f_1(x)}{f_2(x)} dx + \int f_2(x) \log \frac{f_2(x)}{f_1(x)} dx$$

Why KL Divergence?

- 対数尤度の期待値最大化 $\Leftrightarrow$ KLダイバージェンスの最小化

$$\begin{aligned} E_{\theta^*}[\log f(x^n; \theta)] &= \int f(x^n; \theta^*) \log f(x^n; \theta) dx \\ &= - \int f(x^n; \theta^*) \log \frac{f(x^n; \theta^*)}{f(x^n; \theta)} dx + \int f(x^n; \theta^*) \log f(x^n; \theta^*) dx \\ &= -KL(f(x^n; \theta^*) || f(x^n; \theta)) + (\theta \text{によらない項}) \end{aligned}$$

- Shannon Entropyとの自然な対応関係

$$S(f) = -\sum_x f(x) \log f(x)$$

空間が有界な場合には、一様分布 $u(x)$ とのKLダイバージェンスがShannon Entropyのマイナスと定数差を除いて一致する。

しかも、Shannon Entropyは連続分布の場合、定義が基底測度に依存するという致命的な欠点があるが、KLダイバージェンスはそのような問題がない。

Why KL Divergence? (続)

- 大偏差原理に自然に登場する

f-divergence, Csizárのf-divergence, Csizár-Morimotoのf-divergence

- f を $f(1) = 0$ なる $\mathbb{R}$ 上の凸関数とする.

$$D_f(p_1||p_2) := \int f\left(\frac{p_1(x)}{p_2(x)}\right) p_2(x) dx$$

を f -ダイバージェンスという [Csizar(1963), Morimoto(1963)]

- 非負性 (Jensenの不等式より)

- Joint convexity: $\forall \lambda \in [0,1]$,

$$\begin{aligned} D_f(\lambda p_1 + (1 - \lambda)p_2 || \lambda q_1 + (1 - \lambda)q_2) \\ \leq \lambda D_f(p_1||q_1) + (1 - \lambda)D_f(p_2||q_2) \end{aligned}$$

- 同一のMarkovカーネル κ による測度変換に対して, 単調減少 :

$$D_f(p||q) \geq D_f(p_\kappa||q_\kappa)$$

cf. 測度空間の変換 $(X, \mathcal{A}) \rightarrow (Y, \mathcal{B})$ に対するMarkovカーネル $\kappa: \mathcal{B} \times X \rightarrow [0,1]$ とは, $\forall x \in X$, $\kappa(\cdot, x)$ が $(Y, \mathcal{B})$ 上の確率測度となり, $\forall B \in \mathcal{B}$, $\kappa(B, \cdot)$ が $\mathcal{A}$ 可測関数となるもの.

f-divergenceと分解可能性, 不変性 1

- 有限集合 $\mathcal{X} = (x_1, \dots, x_m)$ 上の離散分布 $p = (p_1, \dots, p_m), q = (q_1, \dots, q_m)$ 間の f -ダイバージェンスは以下のように表される.

$$D_f(p||q) = \sum_{i=1}^m f\left(\frac{q_i}{p_i}\right) p_i$$

- このように, $\mathcal{X}$ の各点での確率値の関数に分解できるとき, ダイバージェンスが**分解可能**であるという.
- 有限集合 $\mathcal{X}$ のいくつかを「統合」し, 分割 $A_1, \dots, A_{\tilde{m}}, (\mathcal{X} = \coprod A_i, \tilde{m} < m)$ として, 対応して確率も加算することにより, $\tilde{p} = (\tilde{p}_1, \dots, \tilde{p}_{\tilde{m}}), \tilde{q} = (\tilde{q}_1, \dots, \tilde{q}_{\tilde{m}})$ とする. 任意の p, q とその統合 $\tilde{p}, \tilde{q}$ に関して $D(\tilde{p}||\tilde{q}) \leq D(p||q)$ が成り立つとき, ダイバージェンスが**情報単調性**をもつという.
- f -ダイバージェンスは**情報単調性**をもつ.

∴) x_1, x_2 を統合する場合のみ示せば十分である. $t_1 := \frac{q_1}{p_1}, t_2 := \frac{q_2}{p_2}$ としたとき, Jensenの不等式を用いて,

$$\begin{aligned} (p_1 + p_2) f\left(\frac{q_1 + q_2}{p_1 + p_2}\right) &= (p_1 + p_2) f\left(\frac{p_1}{p_1 + p_2} t_1 + \frac{p_2}{p_1 + p_2} t_2\right) \\ &\leq (p_1 + p_2) \left\{ \frac{p_1}{p_1 + p_2} f(t_1) + \frac{p_2}{p_1 + p_2} f(t_2) \right\} = p_1 f\left(\frac{q_1}{p_1}\right) + p_2 f\left(\frac{q_2}{p_2}\right) \end{aligned}$$

f-divergenceと分解可能性, 不変性 2

$$D_f(p||q) = \sum_{i=1}^m f\left(\frac{q_i}{p_i}\right) p_i \quad f\text{-ダイバージェンス}$$

- 情報単調性 $D(\tilde{p}||\tilde{q}) \leq D(p||q)$ に加えて, 各 $i = 1, \dots, m, j = 1, \dots, \tilde{m}$ に対して, $P(x = x_i | x \in A_j) = Q(x = x_i | x \in A_j)$ のときに限り $D(\tilde{p}||\tilde{q}) = D(p||q)$ が成り立つとき, ダイバージェンスが**不変性**をもつという.
これは, A_j が分布の選択(p or q)に関する十分統計量であるであるとき, またそのときに限り, 統合してもダイバージェンスが減少しないことを意味する.

- f -ダイバージェンスは**不変性**をもつ.

- $\because f$ が線形関数のときは $D_f(p||q) \equiv 0$ となるので, この場合は無視する.

f が線形関数でない凸関数のとき, 先の証明のJensenの不等式を常に等号でみたすのは $t_1 := \frac{q_1}{p_1}, t_2 := \frac{q_2}{p_2}$ に対して $t_1 = t_2$ となるときだけである. 同様にして k 個の値 $x_1, \dots, x_k$ を統合して A_j とするとき, $\frac{q_1}{p_1} = \frac{q_2}{p_2} = \dots = \frac{q_k}{p_k}$ が成立するときのみである.
 $P(x \in A_j) = p_1 + \dots + p_k, Q(x \in A_j) = q_1 + \dots + q_k$ となることに注意すると,

$$P(x = x_i | x \in A_j) = \frac{p_i}{p_1 + \dots + p_k} = \frac{q_i}{q_1 + \dots + q_k} = Q(x = x_i | x \in A_j)$$

- 定理 (甘利『情報幾何学の新展開』 定理 4.1)

3 値以上の有限離散分布の空間に定義される**分解可能で不変なダイバージェンス**は, f -ダイバージェンスのみである.

f-divergenceの例

凸関数 f	f-divergence
$x \log x$	KL-divergence
$-\log x$	逆KL-divergence
$\frac{1}{2} x - 1 $	全変動距離
$(\sqrt{x} - 1)^2$ or $2(1 - \sqrt{x})$	Hellinger距離
$(x - 1)^2$ or $x^2 - 1$ or $x^2 - x$	Pearsonの χ^2 -divergence
$x^{-1} - 1$ or $x^{-1} - x$	Neymanの χ^2 -divergence

この他、情報幾何学で重要な α ダイバージェンスも f ダイバージェンスの一例となっている（後述）

α -divergence

(ただし確率測度だけでなく正測度上の定義)

$$D_A^{(\alpha)}(\mathbf{P} \parallel \mathbf{Q}) = \begin{cases} \frac{1}{\alpha(\alpha-1)} \int \left(q(\mathbf{x}) \left[\left(\frac{p(\mathbf{x})}{q(\mathbf{x})} \right)^\alpha - 1 \right] - \alpha [p(\mathbf{x}) - q(\mathbf{x})] \right) d\mu(\mathbf{x}), & \alpha \neq 0, 1 \\ \int \left(q(\mathbf{x}) \log \frac{q(\mathbf{x})}{p(\mathbf{x})} + p(\mathbf{x}) - q(\mathbf{x}) \right) d\mu(\mathbf{x}), & \alpha = 0 \\ \int \left(p(\mathbf{x}) \log \frac{p(\mathbf{x})}{q(\mathbf{x})} - p(\mathbf{x}) + q(\mathbf{x}) \right) d\mu(\mathbf{x}), & \alpha = 1 \end{cases}$$

- ✓ $\alpha = 0, 1$ は逆KLダイバージェンスおよびKLダイバージェンスに対応している.
- ✓ $\alpha = 0, 1$ は, $\alpha \downarrow 0$, $\alpha \uparrow 1$ の極限值とそれぞれ一致している
- ✓ 情報幾何学から自然に導出されるダイバージェンスである
(ただし, ここでの $\alpha = 0, 1$ が, 情報幾何では $\alpha = 1, -1$ となるので注意)
- ✓ (確率測度だけでなく) 一般の正測度の集合に関しては, Bregmanダイバージェンスとf-ダイバージェンスの積集合と一致する
- ✓ 確率測度上では, 以下の関数を用いたf-ダイバージェンスの一種である

$$f(u) = (u^\alpha - \alpha u + \alpha - 1) / (\alpha^2 - \alpha)$$

Bregman Divergence

- Ω : 閉凸集合
- $\phi: \Omega \rightarrow \mathbb{R}$, 連続微分可能な強凸関数

としたとき, $p, q \in \Omega$ に対して,

$$D_\phi(p, q) := \phi(p) - \phi(q) - \langle \nabla \phi(q), p - q \rangle$$

を ϕ に関する Bregman ダイバージェンス とよぶ

- つまり ϕ の q における Taylor 展開の 1 次近似の, p での値の誤差である.
- 非負性
- 線形性: $D_{\phi_0 + \lambda \phi}(p, q) = D_{\phi_0}(p, q) + \lambda D_\phi(p, q)$ for $\lambda \geq 0$
- 第 1 引数 p に対する強凸性

確率分布の集合も閉凸集合なので, 上の特別の場合となる.

Bregman Divergenceのさらなる性質

- 双対性

$$D_{\phi}(p, q) = D_{\phi^*}(q^*, p^*)$$

ただし, $p^* := \nabla \phi(p)$, $q^* := \nabla \phi(q)$.

また, 凸関数 $\phi: X \rightarrow \bar{\mathbb{R}}$ の凸共役 $\phi^*: X^* \rightarrow \bar{\mathbb{R}}$ とは,

$$\phi^*(x^*) := \sup\{\langle x^*, x \rangle - \phi(x) \mid x \in X\}$$

- ダイバージェンスの期待値の最小化 = 期待値

特に, ダイバージェンスの平均 (or 和) の最小化 = 標本平均
[Banerjee+(2005), Frigyik+(2008)]

- ✓ 確率変数 X の場合 :

$$\operatorname{argmin}_{\mu \in \mathbb{R}} E[D_{\phi}(X, \mu)] = E[X]$$

- ✓ ランダム確率測度 $P \in \mathcal{P}$ の場合 :

$$\operatorname{argmin}_{Q \in \mathcal{P}} E[D_{\phi}(P, Q)] = E[P]$$

Bregman Divergenceの例

Table 1: Bregman divergences generated from some convex functions.

Domain	$\phi(\mathbf{x})$	$d_\phi(\mathbf{x}, \mathbf{y})$	Divergence
$\mathbb{R}$	x^2	$(x - y)^2$	Squared loss
$\mathbb{R}_+$	$x \log x$	$x \log(\frac{x}{y}) - (x - y)$	
$[0, 1]$	$x \log x + (1 - x) \log(1 - x)$	$x \log(\frac{x}{y}) + (1 - x) \log(\frac{1-x}{1-y})$	Logistic loss ³
$\mathbb{R}_{++}$	$-\log x$	$\frac{x}{y} - \log(\frac{x}{y}) - 1$	Itakura-Saito distance
$\mathbb{R}$	e^x	$e^x - e^y - (x - y)e^y$	
$\mathbb{R}^d$	$\ \mathbf{x}\ ^2$	$\ \mathbf{x} - \mathbf{y}\ ^2$	Squared Euclidean distance
$\mathbb{R}^d$	$\mathbf{x}^T A \mathbf{x}$	$(\mathbf{x} - \mathbf{y})^T A (\mathbf{x} - \mathbf{y})$	Mahalanobis distance ⁴
d -Simplex	$\sum_{j=1}^d x_j \log_2 x_j$	$\sum_{j=1}^d x_j \log_2(\frac{x_j}{y_j})$	KL-divergence
$\mathbb{R}_+^d$	$\sum_{j=1}^d x_j \log x_j$	$\sum_{j=1}^d x_j \log(\frac{x_j}{y_j}) - \sum_{j=1}^d (x_j - y_j)$	Generalized I-divergence

Banerjee+(2005)より抜粋

β -divergence


(ただし確率測度だけでなく正測度上の定義)

$$D_B^{(\beta)}(\mathbf{P} \parallel \mathbf{Q}) = \begin{cases} \frac{1}{\beta(\beta-1)} \int (p^\beta(\mathbf{x}) + (\beta-1)q^\beta(\mathbf{x}) - \beta p(\mathbf{x})q^{\beta-1}(\mathbf{x})) d\mu(\mathbf{x}), & \beta \neq 0, 1 \\ \int \left(p(\mathbf{x}) \log\left(\frac{p(\mathbf{x})}{q(\mathbf{x})}\right) - p(\mathbf{x}) + q(\mathbf{x}) \right) d\mu(\mathbf{x}), & \beta = 1 \\ \int \left(\log\left(\frac{q(\mathbf{x})}{p(\mathbf{x})}\right) + \frac{p(\mathbf{x})}{q(\mathbf{x})} - 1 \right) d\mu(\mathbf{x}), & \beta = 0 \end{cases}$$

- ✓ $\beta = 0, 1$ は, $\beta \downarrow 0$, $\beta \uparrow 1$ の極限值とそれぞれ一致している
- ✓ ロバスト性をもつダイバージェンスの代表的なもの
- ✓ 江口真透 (統計数理研究所) らのグループにより提案
- ✓ 以下の関数を用いたBregman divergenceに対応

$$\Phi(t) = \begin{cases} \frac{1}{\beta(\beta-1)} (t^\beta - \beta t + \beta - 1), & \beta \neq 0, 1 \\ t \log(t) - t + 1, & \beta = 1 \\ t - \log(t) - 1, & \beta = 0 \end{cases}$$

確率分布間距離の間の不等式 (Gibbs and Su(2002)よりコピー)



non-metric
distances


Abbreviation	Metric
D	Discrepancy
H	Hellinger distance
I	Relative entropy (or Kullback-Leibler divergence)
K	Kolmogorov (or Uniform) metric
L	Lévy metric
P	Prokhorov metric
S	Separation distance
TV	Total variation distance
W	Wasserstein (or Kantorovich) metric
χ^2	χ^2 distance

on
metric
spaces

on $\mathbb{R}$



FIGURE 1. Relationships among probability metrics. A directed arrow from A to B annotated by a function $h(x)$ means that $d_A \leq h(d_B)$. The symbol $\text{diam } \Omega$ denotes the diameter of the probability space Ω ; bounds involving it are only useful if Ω is bounded. For Ω finite, $d_{\min} = \inf_{x,y \in \Omega} d(x,y)$. The probability metrics take arguments μ, ν ; “ ν dom μ ” indicates that the given bound only holds if ν dominates μ . Other notation and restrictions on applicability are discussed in Section 3.

各ダイバージェンス間の関係



※積集合がKL-ダイバージェンスのみとなる理由は
情報幾何学に関連するので次回以降に説明する

今回扱った 距離やダイバージェンスの問題点



- ・ サポートが異なる分布間はダイバージェンスが発散する 경우가ほとんど
- ・ 分布の近さに、元の空間の点同士の近さが反映されていない
 - ➡ 勾配法などで「徐々に」分布を近づけることができない
 - ➡ この欠点を持たないのがWasserstein距離（次週）

参考文献 1

確率分布間距離, ダイバージェンスの参考書籍

- Deza, M. M., & Deza, E. (2009). *Encyclopedia of distances*. Springer, Berlin, Heidelberg.[分布間距離についても載っている「距離の辞書」]
- Basu, A., Shioya, H., & Park, C. (2011). *Statistical inference: the minimum distance approach*. Chapman and Hall/CRC.[ダイバージェンスの統計的応用に関する教科書]
- Pardo, L. (2018). *Statistical inference based on divergence measures*. Chapman and Hall/CRC.[f-divergenceの統計的応用に関する教科書. ただし, f-divergenceの意味で ϕ -divergenceという用語が用いられている]
- Venturini, G. M. (2015). Statistical distances and probability metrics for multivariate data, ensembles and probability distributions, dissertation, Universidad Carlos III de Madrid. [RKHSを用いた分布間距離について詳しい博士論文]
- 福水健次(2010), 『カーネル法入門—正定値カーネルによるデータ解析 (シリーズ 多変量データの統計科学)』, 朝倉書店 [RKHSを用いた分布間距離についても書かれているカーネル法の教科書]

参考文献 2

ダイバージェンスに関する論文

- Gibbs, A. L., & Su, F. E. (2002). On choosing and bounding probability metrics. *International statistical review*, 70(3), 419-435.[分布間距離やダイバージェンス間の不等式のsurvey]
- Banerjee, A., Merugu, S., Dhillon, I. S., & Ghosh, J. (2005). Clustering with Bregman divergences. *Journal of machine learning research*, 6(Oct), 1705-1749.
- Cha, S. H. (2007). Comprehensive survey on distance/similarity measures between probability density functions. *City*, 1(2), 1.[確率分布間距離の列挙と実験的比較]
- Frigyük, B. A., Srivastava, S., & Gupta, M. R. (2008). Functional Bregman divergence and Bayesian estimation of distributions. *IEEE Transactions on Information Theory*, 54(11), 5130-5139.
- Amari, S. I. (2009). α -Divergence Is Unique, Belonging to Both f - Divergence and Bregman Divergence Classes. *IEEE Transactions on Information Theory*, 55(11), 4925-4931.
- Cichocki, A., & Amari, S. I. (2010). Families of alpha-beta-and gamma-divergences: Flexible and robust measures of similarities. *Entropy*, 12(6), 1532-1568.