




統計科学特論B
幾何学的な統計手法とその理論
第11回 (2021.06.21)

Wasserstein距離

担当： 数理科学科 小林 景



前回までに扱った 距離やダイバージェンスの問題点



- ・ サポートが異なる分布間はダイバージェンスが発散する 경우가ほとんど
 - ・ 分布の近さに、元の空間の点同士の近さが反映されていない
- ➡ 勾配法などで「徐々に」分布を近づけることができない
- ➡ この欠点を持たないのがWasserstein距離

Wasserstein距離

- $\mathbb{R}^d$ 上の有限 p 次モーメントを持つルベーク確率測度 μ, ν 間の p -Wasserstein距離 ($p \geq 1$) は以下により定義される：

$$W_p(\mu, \nu) := \inf_{\pi \in \Pi(\mu, \nu)} \left\{ \int_{\mathbb{R}^d \times \mathbb{R}^d} \|x - y\|^p d\pi(x, y) \right\}^{\frac{1}{p}}$$

ただし、 $\Pi(\mu, \nu)$ は周辺分布が μ および ν となるような $\mathbb{R}^d \times \mathbb{R}^d$ 上のルベーク確率測度の集合.

- 同様にして、より一般の距離空間 (M, d) 上の有限 p 次モーメントをもつラドン確率測度 μ, ν 間の p -Wasserstein距離は以下により定義される：


$$W_p(\mu, \nu) := \inf_{\pi \in \Pi(\mu, \nu)} \left\{ \int_{M \times M} d(x, y)^p d\pi(x, y) \right\}^{\frac{1}{p}}$$

ただし、 $\Pi(\mu, \nu)$ は周辺分布が μ および ν となるような $M \times M$ 上のラドン確率測度の集合.

- 最適な π を **最適輸送** もしくは **最適カップリング** という.

最適輸送問題

採掘場




- $x_1, \dots, x_m (\geq 0)$:
各採掘場からの供給量
- $y_1, \dots, y_n (\geq 0)$:
各工場の需要量
- $x_1 + \dots + x_m = y_1 + \dots + y_n$:
総需要量 = 総供給量
- $w_{ij} (\geq 0)$:
単位量あたりの $i \rightarrow j$ の輸送コスト

最適輸送問題

$$\begin{aligned} & \operatorname{argmin}_{z_{ij}} \sum_{j=1}^m \sum_{i=1}^n w_{ij} z_{ij} \\ & \text{subject to } \sum_{j=1}^m z_{ij} = x_i \quad (i = 1, \dots, n), \\ & \quad \quad \quad \sum_{i=1}^n z_{ij} = y_j \quad (j = 1, \dots, m), \\ & \quad \quad \quad z_{ij} \geq 0 \end{aligned}$$

最適輸送問題 → Wasserstein距離


総需要と総供給を 1 に規格化



m, n 大
連続化



Wikipediaから転載



- $\mu := (x_1, \dots, x_m), \nu := (y_1, \dots, y_n)$ は周辺確率分布になる
- 同時分布は $\pi := (z_{ij})$ になる
- $p_1, \dots, p_m \in \mathbb{R}^d, q_1, \dots, q_m \in \mathbb{R}^d$ に対し, 重み $w_{ij} = \|p_i - q_j\|^p$ とする

→ 最小輸送コストは $W_p(\mu, \nu)^p = \inf_{\pi \in \Pi(\mu, \nu)} \left\{ \int_{\mathbb{R}^d \times \mathbb{R}^d} \|x - y\|^p d\pi(x, y) \right\}$


Wasserstein距離 (例： $\mathbb{R}$ 上の有限離散分布)

- $M = \mathbb{R}$
- $\mu = \frac{1}{n} \sum_{i=1}^n \delta_{x_i}, \nu = \frac{1}{n} \sum_{i=1}^n \delta_{y_i} \quad (x_1 \leq \dots \leq x_n, y_1 \leq \dots \leq y_n)$

このとき,


$$W_p(\mu, \nu) = \left\{ \sum_{i=1}^n |x_i - y_i|^p \right\}^{\frac{1}{p}}$$

つまり, それぞれの最小点から順にマッチングしていったもの




Wasserstein距離（例：1次元連続分布）

- 重み有理数のときの有限離散分布についても同様に考えることができる。



- 極限をとることで、連続分布について以下がいえる。

$$\begin{aligned} W_p(\mu, \nu) &= \left\{ \int_{-\infty}^{\infty} |x - F_\nu^{-1}(F_\mu(x))|^p d\mu \right\}^{\frac{1}{p}} \\ &= \left\{ \int_0^1 |F_\mu^{-1}(r) - F_\nu^{-1}(r)|^p dr \right\}^{\frac{1}{p}} \end{aligned}$$



Wasserstein距離（例：正規分布）

次元 $d \geq 2$ の場合は、一般にWasserstein距離の計算は複雑になるが、正規分布間の2-Wasserstein距離に関しては公式が存在する。

- 正規分布 $P_1 = N(\mu_1, \sigma_1^2)$, $P_2 = N(\mu_2, \sigma_2^2)$ に対して,

$$W_2(P_1, P_2) = \{(\mu_1 - \mu_2)^2 + (\sigma_1 - \sigma_2)^2\}^{\frac{1}{2}}$$

となる。

- 多変量正規分布 $P_1 = N_d(\mu_1, \Sigma_1)$, $P_2 = N_d(\mu_2, \Sigma_2)$ については以下が成立する[Dowson and Landau (1982)]

$$W_2(P_1, P_2) = \left\{ \|\mu_1 - \mu_2\|^2 + \text{tr} \left(\Sigma_1 + \Sigma_2 - 2 \left(\Sigma_1^{1/2} \Sigma_2 \Sigma_1^{1/2} \right)^{1/2} \right) \right\}^{\frac{1}{2}}$$

※これらの式はより一般にlocation-scale familyや楕円形分布族（簡単にいうと平均と分散で分布が定まるような分布族）に関しても成立する。

Wasserstein距離の計算

- Wasserstein距離は直接カップリングを最適化するよりも、Kantorovich双対性の理論を用いると計算を実装しやすくなることが多い。例えば、距離空間 (M, d) 上のサポートが有界な分布に対して、

$$W_1(\mu, \nu) = \sup\left\{ \int_M f(x) d\mu - \int_M f(x) d\nu \mid f: M \rightarrow \mathbb{R}, 1\text{-Lip} \right\}$$

となることを用いる。(Villani (2003, 2008), Peyré&Cuturi(2019)等参照)

- ユークリッド距離上の有限確率分布のWasserstein距離の計算は、各種ソフトウェアで関数が用意されている。(例えばRではtransportパッケージのwasserstein()等)
- 関数 f をニューラルネットワークで最適化する手法が近年研究されている
- その他、Wasserstein距離の計算の工夫についてはPeyré&Cuturi(2019)が詳しい。

Wasserstein距離の理論の発展

- (M, d) がポーランド空間（完備可分距離づけ可能空間）のとき、有限 p 次モーメントをもつラドン確率測度の空間に Wasserstein距離を入れた空間もまた、ポーランド空間になる.
- 微分幾何のリッチ曲率は、Wasserstein距離を用いても定義することができる[桑江他(2015)]. また、アナロジーからグラフ上のリッチ曲率も提案されている[Olliver(2009), Lin+(2011)].
- Villani (2003, 2008)は、Wasserstein距離やKantorovich双対の理論を、より一般の（擬）距離空間に拡張している.
- 確率分布のみでなく、距離空間ごとに変形し、 $d_X(x, x')$ と $d_Y(y, y')$ の差の2乗リスクをなるべく小さくするようなカップリングを計算するGromov-Wasserstein距離も提案されている. (Peyré&Cuturi(2019) 参照)

エントロピー正則化

- 近年、エントロピー正則化を導入することにより最適輸送問題を解き、Wasserstein距離の近似値を効率的に計算するアルゴリズムがCuturiらによって提案され、広く用いられている。

$$W_p^\lambda(\mu, \nu) = \inf_{\pi \in \Pi(\mu, \nu)} \left\{ \int_{M \times M} d(x, y)^p d\pi(x, y) - \lambda H(\pi) \right\}^{1/p}$$

ただし、 $H(\pi) := - \int_{M \times M} \log \left(\frac{d\pi}{d\nu} \right) d\pi$ はシャノンエントロピーで、 λ は小さい正の値とする。

- $H(\pi)$ の代わりに π の相互情報量 $\tilde{H}(\pi) := KL(\pi || \mu \otimes \nu)$ を用いても定数の差のみで本質的に同値である。
- この正則化により、最適化問題が強凸最適化となる。
また、離散化した最適化問題の解の形が制限され、Sinkhornアルゴリズムとよばれる方法で逐次的に計算できる。
- 正規分布の場合の $W_p^\lambda(\mu, \nu)$ や、q-正規分布（多変量t分布）をTsallis entropyで正則化した場合の厳密な値がTong and K.(2021)により導出されている。


Wasserstein最短経路を用いた画像の補間 [Solomon+(2015)]

適当な正則条件のもと、 W_2 距離における確率分布間の最短経路は以下の μ_t ($t \in [0,1]$)で計算できる.


$$\mu_t = \inf_{\mu \in \text{Prob}(M)} [(1-t)\mathcal{W}_2^2(\mu_0, \mu) + t\mathcal{W}_2^2(\mu, \mu_1)]$$

ただし実際には、 W_2 距離の計算を容易にするため、以下のようにエントロピー関数の正則化項を加えて、 π に関する強凸関数にしたもの（を離散近似したもの）を用いる.


$$\mathcal{W}_{2,\gamma}^2(\mu_0, \mu_1) \stackrel{\text{def.}}{=} \inf_{\pi \in \Pi} \left[\iint_{M \times M} d(x, y)^2 \pi(x, y) dx dy - \gamma H(\pi) \right]$$



Euclidean barycenter



Wasserstein barycenter



いずれも[Solomon+(2015)]より抜粋

Wasserstein GAN

- GAN (Generative Adversarial Networks) とは、学習データ（例えば、人の顔画像のデータ）が得られているとき、

1. 識別器を騙すような偽データを生成する
2. 偽データと真のデータを識別できるような識別器を学習する

ということを繰り返して、偽データの精度を上げる手法である。これにより、元データにはないが、元データに近いデータを生成することができる。[Goodfellow+(2014)]

（例：「人の顔だが、実在の人ではない画像」など）

学習には、生成ネットワークと識別ネットワークの2つのニューラルネットワークを競合させる形で行う。

偽データ分布と真のデータ分布の近さの規準として、通常は Jensen-Shannon divergenceなどが用いられるが、Wasserstein 距離を用いた Wasserstein GANが提案されている。
[Arjovsky+(2017)]


GANの応用例

- GANにより生成された実在しない顔の写真[Radford+(2015)より]



- [Arjovsky+(2017)]では、GANで自動生成されたインテリアの画像を Wasserstein GANのものと比較し、生成される画像が安定すると主張されている。

Optimal Transport GANによる犬画像生成



左：optimal transportあり 右：通常のGAN


Salimans+(ICLR2018)より引用

※ 彼らはWasserstein GANと似た手法をOptimal Transport GANと名付けており，数値実験によっても改善が確認されている．

追記：



2014



2015



2016



2017

上の図は次から引用

Brundage, M., Avin, S., Clark, J., Toner, H., Eckersley, P., Garfinkel, B., ... & Amodei, D. (2018). The Malicious Use of Artificial Intelligence: Forecasting, Prevention, and Mitigation

その他， GANの様々な応用例については例えば以下にまとめられている：

<https://machinelearningmastery.com/impressive-applications-of-generative-adversarial-networks/>

<https://blog.eduonix.com/artificial-intelligence/grand-finale-applications-gans/>

レポート課題

• 課題 8

- (1) 授業で扱った確率分布間の距離もしくはダイバージェンス 3 種類について, その性質の違いが明確になるような人工的なデータを複数作成し, 距離やダイバージェンス値の違いを比較せよ.
- (2) 適当な実データに対して, (1)と同じ距離もしくはダイバージェンス 3 種類を用いてデータの差異の評価を行い, 結果を考察せよ.

• 課題 9

- (1) 多変量正規分布 $N_d(\mu_1, \Sigma_1), N_d(\mu_2, \Sigma_2)$ について, KLダイバージェンスおよびWasserstein距離を計算せよ. 証明も書くこと.
- (2) 3 点 (x_1, x_2, x_3) 間の距離が $a = d(x_1, x_2), b = d(x_2, x_3), c = d(x_3, x_1)$ であるとき, $\{x_1, x_2, x_3\}$ 上の確率分布 $P = (p_1, p_2, p_3), Q = (q_1, q_2, q_3)$ 間のWasserstein距離を計算せよ. ただし, $p_i, q_i \geq 0 (i = 1, \dots, 3), \sum_{i=1}^3 p_i = \sum_{i=1}^3 q_i = 1$ とする.

期末レポート課題（決定版）

これまで出題した課題 1 ～ 9 のうち， 1 ～ 3 問を選んで解き提出せよ．

ただし， 1 問につき 5 ページ以下を目安として結果を簡潔にまとめること．また，計算に用いたR等のコマンドやコードはレポートの最後にまとめて添付し，上記のページ数には含めない．

表紙に名前，学籍番号，選んだ問題番号を表記すること．また，レポート作成の際に協力した人や参考にした文献があればレポート内に明記すること．

【提出期限】 7 月 2 3 日（金） 23:59

【提出方法】 A4サイズ， 1 段組のPDFをCanvasにアップロードして提出（手書きレポートのスキャンも一応可とする）

• 評定の基準：提出課題数が

3 つ ⇒ 評定Sかそれ以下， 2 つ ⇒ A以下， 1 つ ⇒ B以下

参考文献 1

最適輸送と Wasserstein 距離の理論に関する書籍, その他

- Villani, C. (2003). *Topics in optimal transportation* (No. 58). American Mathematical Soc .[最適輸送に関する理論の教科書]
- Villani, C. (2008). *Optimal transport: old and new* (Vol. 338). Springer Science & Business Media.[最適輸送に関する理論の教科書 2]
- Peyré, G., & Cuturi, M. (2019). Computational optimal transport: With applications to data science. *Foundations and Trends® in Machine Learning*, 11(5-6), 355-607.(arXiv:1803.00567)
[Wasserstein 距離や最適輸送問題に関して, データ解析, 計算効率, 理論の話題をまとめた書籍]
- 桑江他 (2015). 最適輸送理論とリッチ曲率 ~ 物を運ぶと曲率が分かる ~, *Encounter with Mathematics* 63回, 2015年2月20,21日[研究集会の資料がネット検索で見つかる]

参考文献 2

Wasserstein距離に関する論文

- Dowson, D. C., & Landau, B. V. (1982). The Fréchet distance between multivariate normal distributions. *Journal of multivariate analysis*, 12(3), 450-455.
- Solomon, J., De Goes, F., Peyré, G., Cuturi, M., Butscher, A., Nguyen, A., ... & Guibas, L. (2015). Convolutional wasserstein distances: Efficient optimal transportation on geometric domains. *ACM Transactions on Graphics (TOG)*, 34(4), 66.
- Tong, Q. and Kobayashi, K. (2021): Entropy-regularized optimal transport on multivariate normal and q-normal distributions, *Entropy*, 23(3), 302.

参考文献 3

グラフリッチ曲率に関する論文

- Lin, Y., Lu, L., & Yau, S. T. (2011). Ricci curvature of graphs. *Tohoku Mathematical Journal, Second Series*, 63(4), 605-627.
- Ollivier, Y. (2009). Ricci curvature of Markov chains on metric spaces. *Journal of Functional Analysis*, 256(3), 810-864.

GANに関する論文

- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A. & Bengio, Y. (2014). Generative adversarial nets. In *Advances in neural information processing systems* (pp. 2672-2680).
- Radford, A., Metz, L., & Chintala, S. (2015). Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*.
- Arjovsky, M., Chintala, S., & Bottou, L. (2017). Wasserstein gan. *arXiv preprint arXiv:1701.07875*.
- Salimans, T., Zhang, H., Radford, A., & Metaxas, D. (2018). Improving GANs Using Optimal Transport, *In International Conference on Learning Representations*, (arXiv:1803.05573).